

PDET Municipality Boundaries Dataset Integration

Entrega Final

Eliana Katherine Cepeda

Juan Diego Gonzalez

Mateo Moreno

Noviembre 23, 2025

1. Introducción

La rápida transformación de la infraestructura energética en Colombia exige enfoques innovadores para identificar zonas adecuadas para la implementación de soluciones de energía renovable. Como parte de una estrategia nacional más amplia para promover el desarrollo sostenible y mejorar el acceso a la energía en regiones vulnerables, la Oficina de Investigación e Información de la Unidad de Planeación Minero Energética (UPME) impulsó una iniciativa estratégica orientada a evaluar la viabilidad de la energía solar en territorios priorizados.

Este proyecto apoya directamente ese objetivo mediante el diseño e implementación de un flujo de análisis geoespacial reproducible para estimar el potencial solar de las cubiertas de edificaciones en municipios priorizados. En particular, se hace énfasis en los territorios PDET (Programas de Desarrollo con Enfoque Territorial), que constituyen un foco clave para las intervenciones de posconflicto y el fortalecimiento de la infraestructura en Colombia.

A partir de datos geoespaciales abiertos, el proyecto busca estimar el número de edificaciones y el área total de cubiertas potencialmente disponibles para la instalación de paneles solares. Estos conjuntos de datos que incluyen miles de millones de huellas de edificaciones derivadas de imágenes satelitales de alta resolución representan un insumo valioso para cuantificar superficies de captación de energía tanto en contextos urbanos como rurales.

En coherencia con la infraestructura tecnológica y los objetivos de modernización de la UPME, la metodología se diseñó sobre soluciones de datos NoSQL, habilitando almacenamiento escalable, consultas eficientes y operaciones espaciales flexibles. El resultado es un informe técnico que documenta la metodología, presenta los resultados principales y formula recomendaciones para identificar ubicaciones óptimas de proyectos de demostración de energía solar en los municipios seleccionados.

De esta forma, el proyecto integra herramientas modernas de ciencia de datos con necesidades reales de política energética, articulando innovación técnica y planificación estratégica en apoyo a la transición energética y a la equidad territorial en Colombia.

2. Planteamiento del problema y alcance

La Oficina de Investigación e Información de la UPME busca un aliado estratégico para las fases iniciales de una iniciativa orientada a identificar ubicaciones para proyectos demostrativos de energías alternativas. Dentro de estas alternativas, la UPME se propone evaluar la factibilidad de granjas solares y de soluciones fotovoltaicas distribuidas en distintas regiones del país.

Para seleccionar los posibles lugares de intervención, los actores clave decidieron priorizar los municipios clasificados como territorios PDET. El objetivo principal del proyecto es determinar cuántas edificaciones existen en cada municipio y estimar el área total de cubierta disponible para instalación de paneles solares. Cuanto mayor sea el área de cubierta en un municipio, mayor será el potencial de captación de energía limpia mediante la instalación de paneles en esos techos.

La UPME requiere un informe detallado que incluya una metodología reproducible para el conteo de edificaciones y la agregación de su área de cubierta, para cada municipio PDET y empleando diferentes fuentes de datos abiertos.

Dado que la Oficina ha adquirido nuevas tecnologías e infraestructura, un requisito central del proyecto es la utilización de soluciones NoSQL en la metodología propuesta. Adicionalmente, se exige la evaluación de conjuntos de datos abiertos que permitan consultar e identificar edificaciones dentro de los territorios objetivo, con el fin de comparar los resultados obtenidos a partir de cada fuente. Las dos fuentes principales utilizadas son:

- **Microsoft Building Footprints:** huellas de edificaciones detectadas a partir de imágenes de Bing Maps, con más de 999 millones de edificaciones a nivel mundial, publicadas como datos abiertos.
- **Google Open Buildings:** conjunto de datos con aproximadamente 1,8 mil millones de detecciones de edificaciones en África, Asia y América Latina, incluyendo Colombia.

Como apoyo geográfico oficial, el DANE proporciona el **Marco Geoestadístico Nacional (MGN)**, que incluye los límites de todos los municipios del país. En este proyecto solo se consideran los municipios designados como territorios PDET, de acuerdo con el listado oficial.

3. Metodología y documentación del proceso

3.1. Arquitectura tecnológica y diseño NoSQL

Para cumplir con los requisitos de escalabilidad, flexibilidad y análisis geoespacial, se seleccionó el siguiente stack tecnológico:

- Base de datos NoSQL: MongoDB, por su modelo orientado a documentos (JSON/GeoJSON) y su motor de consultas geoespaciales con índices 2dsphere.
- Lenguaje de programación: Python, utilizando pymongo para la interacción con la base de datos, y geopandas/pandas para lectura, limpieza y transformación de los datos originales.
- Control de versiones: Git y GitHub para el seguimiento de avances semanales y del código.

Se modelaron dos entidades principales:

1. **Municipio (colección municipios):**
 - Código DANE, nombre del municipio y departamento.
 - Indicador booleano pdet.
 - Geometría tipo Polygon/MultiPolygon en EPSG:4326.

2. Edificio (colecciones de edificaciones por fuente):

- fuente: "google" o "microsoft".
- area_m2: área de la huella de edificio en metros cuadrados.
- Campo clave: centroide, almacenado como Point en GeoJSON.
- (En las etapas iniciales se trabajó con geometrías completas, pero la implementación final se hizo cargando solamente los centroides a MongoDB, debido a problemas de tiempo de procesamiento y memoria en el computador).

Sobre estas colecciones se definieron índices:

- Índice 2dsphere sobre geometria en municipios.
- Índice 2dsphere sobre centroide en los edificios.
- Índices adicionales por fuente y por codigo_dane_municipio para consultas rápidas.

3.2. Integración de límites municipales PDET

1. Descarga del shapefile MGN_ADM_MPIO_GRAFICO desde el geoportal del DANE.
2. Carga del shapefile con GeoPandas y verificación de columnas y geometrías.
3. Lectura del archivo Excel con los 170 municipios PDET.
4. Cruce de códigos DANE para filtrar únicamente los municipios PDET.
5. Conversión a GeoJSON y carga en MongoDB en la colección municipios.
6. Creación del índice 2dsphere sobre el campo de geometría y pruebas de consultas espaciales con puntos de ejemplo.

Como resultado se obtuvo una colección con los 170 municipios PDET y capacidades de consulta geográfica funcionales.

3.3. Carga y procesamiento de huellas de edificaciones

En la fase siguiente se trabajó con muestras de Google Open Buildings y Microsoft Building Footprints:

- Estandarización del esquema (geometria, area_m2, fuente, confianza para Google).
- Para Microsoft, cálculo del área reprojectando las geometrías a EPSG:3116, de forma que el área en grados se transformara a metros y pudiera almacenarse en area_m2.
- 2Entrega
- Implementación inicial de un enfoque ETL: lectura por *chunks*, filtrado a PDET en Python y carga de solo esos edificios filtrados a MongoDB.

Sin embargo, este enfoque ETL resultó poco escalable: el consumo de memoria y los tiempos de cómputo eran muy altos, al punto de que los procesos se detenían antes de completar las corridas sobre grandes volúmenes de datos.

3.4. Estrategia final ELT y flujo de agregación (Entrega 4)

En la fase final del proyecto se consolidó una estrategia de “Cargar–Luego–Analizar” (ELT), que reemplazó por completo el intento inicial de hacer filtrado previo en Python (ETL), el cual resultó inviable por las restricciones de memoria y tiempo de ejecución.

Los cambios clave fueron:

1. Carga masiva y unificación de esquema

- Se cargaron en bruto todos los edificios de Microsoft (~6 millones) y Google (~32 millones) a MongoDB, sin filtrar previamente por municipios PDET.
- Durante la carga, se calculó el área de cada edificio de Microsoft re proyectando temporalmente las geometrías a un sistema de coordenadas plano (EPSG:3116) y almacenando el resultado en el campo `area_m2`, mientras que en Google se reutilizó el campo `area_in_meters` renombrado a `area_m2`.
- Ambas fuentes quedaron normalizadas en un esquema común, con al menos: `fuelle` (`google/microsoft`), `area_m2` y `geometria` en formato GeoJSON (EPSG:4326), apto para índices 2dsphere.

2. Uso de geometría simplificada en MongoDB

- Para reducir el peso de las geometrías y evitar que la máquina se quedara sin memoria, al momento de la carga se almacenó en MongoDB una representación simplificada de cada edificio (basada en su centroide) en el campo `geometria`.
- Las consultas geoespaciales, por tanto, se realizan sobre estos puntos representativos en lugar de sobre el polígono completo, lo que disminuye drásticamente el costo computacional manteniendo la capacidad de asignar cada edificio a un municipio.

3. Consulta iterativa por municipios PDET

- Un script de Python consulta la colección `municipios` con un `.find({})` y construye una lista `municipios_pdet` con los 170 municipios y sus geometrías.
- El script recorre esa lista y, para cada municipio, extrae el polígono PDET y lanza dos pipelines de agregación en MongoDB: uno para Microsoft y otro para Google.
- Cada pipeline sigue la misma estructura:
 - Fase `$match`: usa `$geoIntersects` sobre `geometria` para filtrar todos los edificios cuyo punto representativo cae dentro del polígono del municipio.
 - Fase `$group`: calcula el número total de edificios (conteo) y la suma de `area_m2` (`area_total`) dentro de ese municipio.

4Entrega

4. Join fuera de la base de datos

- Por limitaciones de la versión de MongoDB utilizada, el join entre los resultados de Microsoft y Google no se implementó dentro del servidor (no se usó un `$lookup` geoespacial complejo).
- En su lugar, los resultados agregados se van acumulando en un DataFrame de Pandas en Python, que consolida para cada municipio: código DANE, nombre, fuente, conteo y área total.
- Al finalizar el bucle sobre los 170 municipios, el DataFrame consolidado se exporta a `.csv/.xlsx`, que es el archivo final utilizado para el análisis y la construcción de visualizaciones.

4Entrega

5. Manejo de casos sin edificios

- El script controla explícitamente los casos donde MongoDB no retorna resultados para alguna fuente en un municipio (por ejemplo, si no hay edificios de Google en un municipio determinado), rellenando esos valores con ceros para evitar errores en el join y mantener coherencia en la tabla final.

4. Resultados y visualizaciones

4.1. Estadísticos descriptivos

A partir de la fase de EDA, se obtuvieron estadísticas descriptivas de área para los edificios en territorios PDET:

- Microsoft Building Footprints (PDET):**
 - Área total $\approx 13,16$ millones de m^2 .
 - Área promedio $\approx 139 m^2$.
 - Área mínima $\approx 20 m^2$; área máxima $\approx 55.228 m^2$.
- Google Open Buildings (PDET):**
 - Área total $\approx 8,82$ millones de m^2 .
 - Área promedio $\approx 88 m^2$.
 - Área mínima $\approx 2,75 m^2$; área máxima $\approx 6.693 m^2$.

Estas diferencias reflejan que Microsoft tiende a representar edificaciones con huellas más grandes (posiblemente fusionando estructuras), mientras que Google produce huellas más pequeñas y fragmentadas.

4.2. Resultados agregados por municipio PDET

El archivo Excel final se obtiene a partir del join en Python de los resultados agregados de Microsoft y Google. Para cada uno de los 170 municipios PDET, el DataFrame consolidado incluye: nombre del municipio, código DANE, departamento, conteo de edificaciones y área total de techos por fuente (google_conteo, google_area_total_m2, microsoft_conteo, microsoft_area_total_m2).

Este DataFrame se exporta a un archivo .csv/.xlsx, que luego se organizó en Excel para facilitar la revisión manual. En la siguiente captura

	A	B	C	D	E	F	G
1	municipio_nombre	municipio_codigo_dane	departamento	google_conteo	google_area_total_m2	microsoft_conteo	microsoft_area_total_m2
2	AMALFI	5031	ANTIOQUIA	2983	1856396093	5184	7,59697E+15
3	ANORÍ	5040	ANTIOQUIA	7652	4945226483	5318	5,42218E+15
4	APARTADÓ	5045	ANTIOQUIA	36337	3606578248	9477	2,01108E+15
5	BRICEÑO	5107	ANTIOQUIA	3565	2090404883	2113	2,08272E+15
6	CÁCERES	5120	ANTIOQUIA	12425	9725476676	6762	6,84848E+15
7	CAREPA	5147	ANTIOQUIA	16657	17266204024	7039	1,12383E+16
8	CAUCASIA	5154	ANTIOQUIA	30474	2771754468	10208	1,73732E+16
9	CHIGORODÓ	5172	ANTIOQUIA	18871	18830855872	7078	1,68087E+16
10	DABEIBA	5234	ANTIOQUIA	7696	5061714122	4766	4,94928E+15
11	EL BAGRE	5250	ANTIOQUIA	14768	13147871012	7134	7,48676E+15
12	ITUANGO	5361	ANTIOQUIA	9063	627500743	5776	6,00723E+15
13	MURINDÓ	5475	ANTIOQUIA	0	0	927	8,59907E+15
14	MUTATÁ	5480	ANTIOQUIA	5537	4693866149	3118	3,41967E+15
15	NECOCLÍ	5490	ANTIOQUIA	32173	23441543329	12879	1,21782E+16
16	NECHÍ	5495	ANTIOQUIA	3492	2319781305	2852	2,5068E+16
17	REMEDIOS	5604	ANTIOQUIA	13248	9630312446	8345	9,26883E+15
18	SAN PEDRO DE URABÁ	5665	ANTIOQUIA	22034	16447550511	9947	1,14195E+15
19	SEGOVIA	5736	ANTIOQUIA	16158	119618533	7428	9,13841E+15

se observan, por ejemplo, los municipios PDET de Antioquia (Amalfi, Anorí, Apartadó, Briceño, Cáceres, Cauca, entre otros) con sus conteos y áreas totales diferenciadas por fuente, lo que permite comparar de forma directa las estimaciones de potencial entre Google y Microsoft.

4.3. Visualizaciones geospaciales

A partir del archivo tabulado consolidado se generó una capa geográfica enriquecida, uniendo la tabla de resultados con la capa de municipios PDET mediante el código DANE. De esta forma, cada polígono de municipio incorpora como atributos el número de edificios y el área total de techos por fuente, así como indicadores derivados (por ejemplo, área promedio por edificio).

Con esta capa se construyeron los siguientes mapas coropléticos:

- Mapas de conteo de edificios por municipio PDET para Microsoft y para Google.
- Mapas de área total de techos por municipio PDET para cada fuente.
- Comparaciones visuales que permiten identificar diferencias sistemáticas entre Google y Microsoft en ciertas regiones.

Las figuras incluidas en la Entrega 4 (página 6) muestran, por ejemplo, el “Conteo de Edificios de Microsoft (PDET) en Colombia” y el “Conteo de Edificios de Google (PDET) en Colombia”, donde se aprecian clústeres de alta densidad de edificaciones en varios municipios PDET y contrastes en la intensidad de color entre ambas fuentes. Estas visualizaciones facilitan la interpretación espacial del potencial solar y la priorización de territorios para intervenciones posteriores.

5. Discusión

5.1. Fortalezas de la metodología

- **Uso efectivo de NoSQL:** La migración desde un intento ETL en Python hacia una arquitectura ELT con MongoDB permitió cargar en bruto alrededor de 38 millones de registros y delegar a la base de datos el filtrado y la agregación geoespacial mediante índices 2dsphere y \$geoIntersects, reduciendo de días a minutos los tiempos de procesamiento.
- **Flujo ELT reproducible:** La transición de un enfoque ETL en Python a un enfoque ELT, donde la base de datos ejecuta el filtrado y las agregaciones, permitió superar restricciones de memoria y tiempo, y dejó un pipeline claramente documentado para re-ejecuciones futuras.
- **Comparabilidad entre fuentes:** Al estandarizar ambos conjuntos de datos en un esquema común (area_m2, fuente) es posible comparar de forma directa los resultados de Google y Microsoft para cada municipio PDET.
- **Integración híbrida MongoDB–Python:** Aunque el join entre fuentes no se realizó dentro de MongoDB por limitaciones de versión, la combinación de agregaciones geoespaciales en el servidor con un join final en Python/Excel demostró ser una solución práctica y reproducible, compatible con la infraestructura disponible.

5.2. Limitaciones

1. **Uso de centroides en lugar de polígonos completos**
 - Por motivos de rendimiento y memoria, la carga a MongoDB se hizo usando solo los centroides de las edificaciones.
 - Esto puede generar errores en casos de edificaciones muy extensas o que cruzan límites municipales, ya que la asignación se basa en un único punto representativo.

- También impide realizar análisis más avanzados de intersección parcial de áreas.
- 2. **Restricciones de hardware local**
 - El proyecto se ejecutó en un entorno de cómputo con RAM limitada, lo que obligó a replantear el diseño inicial y condiciona la escala de futuros análisis si no se migra a infraestructura más robusta.
- 3. **Calidad y completitud de los datos abiertos**
 - Tanto Google como Microsoft presentan falsos positivos/negativos y diferencias en cobertura según región.
 - Las discrepancias entre áreas promedio y totales indican que estos resultados deben interpretarse como estimaciones de orden de magnitud, no como cifras catastrales exactas.
- 4. **No se modelan condiciones técnicas de instalación**
 - El análisis se limita al conteo de edificios y área de techos; no se consideran orientación, pendiente, sombras, restricciones estructurales ni viabilidad económica detallada de proyectos solares.
- 5. **Join entre fuentes fuera de la base de datos**
 - Debido a restricciones de la versión de MongoDB utilizada, no fue posible implementar un join geoespacial avanzado (**\$lookup** con pipeline) directamente en el servidor. Esto obligó a realizar el cruce entre los resultados agregados de Microsoft y Google en la capa de análisis (Python/Excel). Aunque la solución es funcional, implica mantener lógica adicional fuera de la base de datos y coordinar dos pasos separados (agregación en Mongo y consolidación en Python).

6. Recomendaciones para la UPME

6.1. Sobre el uso de los conjuntos de datos

1. **Usar ambas fuentes de manera complementaria**
 - Se recomienda utilizar simultáneamente Google Open Buildings y Microsoft Building Footprints para obtener rangos de estimación de área de techos por municipio:
 - Valores basados en Google pueden interpretarse como estimaciones conservadoras.
 - Valores basados en Microsoft pueden servir como cota superior del potencial.
2. **Validación local en municipios prioritarios**
 - Para los municipios que resulten más prometedores según este análisis (mayor conteo y área total de techos), se sugiere realizar validaciones con imágenes satelitales de mayor resolución, información catastral o visitas de campo.
3. **Actualización periódica de datos**
 - A medida que se publiquen nuevas versiones de estos conjuntos de datos, la UPME debería re-ejecutar el flujo ELT para mantener actualizadas las estimaciones de potencial solar en territorios PDET.

6.2. Sobre la metodología y la infraestructura tecnológica

1. Migrar a una infraestructura de MongoDB más robusta

- Para un uso operativo, se aconseja desplegar MongoDB en un servidor dedicado o en la nube, con mayor capacidad de CPU, RAM y almacenamiento, lo que permitiría trabajar directamente con polígonos completos y escalar el análisis a todo el país.

2. Reintroducir polígonos cuando la infraestructura lo permita

- Una vez superadas las restricciones de hardware, se recomienda cargar las huellas completas de edificaciones y recalcular las agregaciones usando intersecciones de polígonos, lo que mejorará la precisión de las áreas municipales y posibilitará nuevos indicadores.

3. Automatizar el flujo ELT

- Empaquetar el proceso de descarga, carga, indexación, agregación y exportación de resultados en scripts o *pipelines* automatizados, de modo que analistas de la UPME puedan repetir el proceso con mínima intervención manual.

6.3. Próximos pasos analíticos

1. Modelos de aptitud de techos

- Integrar datos de elevación, uso del suelo y posibles sombras para estimar el porcentaje de área de techo realmente utilizable para paneles fotovoltaicos.

2. Articulación con variables socioeconómicas y de red eléctrica

- Combinar el potencial de techos con información sobre pobreza energética, calidad del servicio eléctrico y capacidad de la red, para priorizar proyectos en municipios donde el impacto social sea mayor.

3. Traducción de área a capacidad instalada y energía anual

- Convertir el área de cubierta en indicadores de capacidad instalada potencial (kW) y energía generada (kWh/año) bajo supuestos estándar de eficiencia y factores de planta, facilitando la comparación con metas de política pública.

7. Conclusiones

El proyecto desarrolló y documentó una metodología basada en NoSQL y análisis geoespacial para estimar el potencial solar de cubiertas en los 170 municipios PDET de Colombia, utilizando datos abiertos de edificaciones de Google y Microsoft y límites municipales oficiales del DANE.

Los principales logros son:

- Implementación de un flujo ELT reproducible que aprovecha MongoDB como motor de cómputo geoespacial.
- Carga y manejo eficiente de decenas de millones de registros de edificaciones mediante el uso de centroides e índices 2dsphere.
- Generación de un archivo tabular con conteos y área total de techos por municipio PDET, para ambas fuentes, y elaboración de mapas coropléticos que permiten visualizar el potencial relativo entre territorios.

Aunque el uso de centroides y las limitaciones de hardware introducen incertidumbres, los resultados obtenidos proporcionan a la UPME una herramienta de primera aproximación para priorizar municipios PDET con mayor potencial de cubiertas para energía solar y para orientar estudios más detallados y proyectos demostrativos.

En síntesis, el trabajo cumple con los requerimientos establecidos: documenta todo el proceso, presenta resultados y visualizaciones claros, ofrece un contenido metodológico completo y formula recomendaciones alineadas con los objetivos de la UPME de promover la transición energética y reducir brechas territoriales en Colombia.